2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

EPA Fuel Economy 2025

Grupo 13

Sanchez Islas Joaquin

Bejarano Rodrigo Ruben

Hultstrom Denda Joaquín

1. Introducción

La economía de combustible y las emisiones de un vehículo dependen tanto de sus características como de las condiciones en las que circula. Un mismo vehículo puede dar resultados distintos en ciudad, en autopista o en una prueba a baja temperatura. Por eso, para comparar vehículos es necesario tener en cuenta cómo se realizaron los ensayos.

En este trabajo analizamos EPA Fuel Economy, correspondiente a vehículos de año modelo 2025. La base reúne ensayos realizados por la Agencia de Protección Ambiental de Estados Unidos (EPA) y por fabricantes que informan sus resultados al organismo. Estos datos se utilizan en la elaboración de estimaciones de economía de combustible y en programas vinculados con la eficiencia vehicular [1].

El archivo contiene **4287 registros y 67 variables**. Incluye información del fabricante, motor, transmisión, tracción, combustible, procedimiento y emisiones. La economía de combustible se expresa en millas por galón (MPG): un valor mayor indica que se recorre más distancia con la misma cantidad de combustible.

El objetivo fue conocer la base, revisar sus problemas y evaluar seis hipótesis: tres propuestas por la cátedra y tres planteadas por el grupo. Trabajamos principalmente con vehículos ensayados con combustibles de combustión. Los procedimientos urbanos, de autopista, conducción agresiva, aire acondicionado y frío representan condiciones diferentes y no se mezclaron sin distinguirlas [2].

Durante la exploración encontramos valores faltantes, algunas mediciones sospechosas y varias filas para una misma configuración. Conservamos la base original, realizamos las correcciones en una copia y seleccionamos los datos necesarios para cada análisis. La limpieza y la preparación de cada hipótesis se detallan en las secciones siguientes.

El informe presenta primero el análisis exploratorio y la limpieza. Luego desarrolla las seis hipótesis, su forma de evaluación y sus resultados. Por último, reúne las conclusiones y las limitaciones. Los cálculos se encuentran en **TPE.ipynb**: secciones 1 y 2 para exploración y limpieza, sección 3 para las hipótesis propias y apartados 4A a 4F para su validación.

2. Análisis exploratorio de los datos

2.1. Estructura y principales observaciones

Cada fila representa un registro de ensayo, no necesariamente un vehículo diferente. Identificamos **1448 configuraciones**, de las cuales 1293 aparecen en más de un registro. La clave combina código del fabricante, identificador del vehículo y número de configuración, según los metadatos [3]. No encontramos filas completamente idénticas. Aunque la metadata describe Test Number como único, hay 213 identificadores repetidos (273 filas adicionales). En el subconjunto urbano de 4A son 89 identificadores y 110 filas adicionales, con MPG coincidentes; se evita contarlos dos veces. Esto motivó la preparación de una observación por configuración cuando correspondía.

La base reúne 32 códigos de fabricante, 14 procedimientos, 11 tipos de combustible y cinco sistemas de tracción. La gasolina Tier 2 concentra 3236 registros (75,48 %) y la electricidad, 654 (15,26 %). Estas frecuencias describen los ensayos disponibles, no las ventas ni la composición del parque automotor.

La potencia tiene una mediana de 305 HP y una media de 340,70 HP. La Figura 1 muestra que hay pocos registros muy elevados y una mayor concentración en valores menores. El peso equivalente de ensayo tiene una mediana de 4750 lb. Los motores de cuatro, seis y ocho cilindros predominan entre los registros con ese dato. Estas observaciones motivaron estudiar la cantidad de cilindros y la relación de las características técnicas con la economía de combustible.

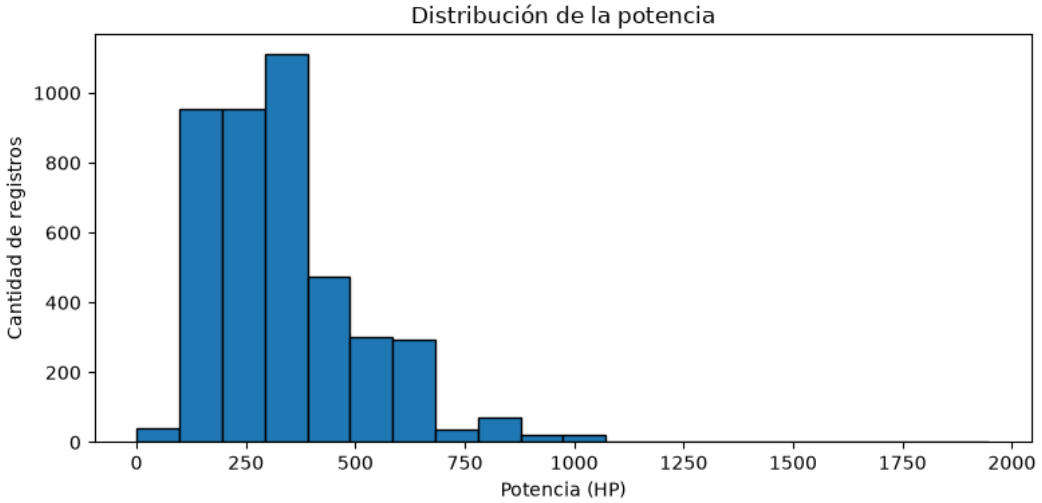


Figura 1. Distribución de potencia en los registros originales. Fuente: TPE.ipynb, sección 1, apartado Rated Horsepower.

2.2. Valores faltantes y emisiones

Hay faltantes en 24 de las 67 variables. Su presencia no siempre indica un error: los campos ADFE solo se completan cuando la economía de combustible se deriva analíticamente. Por eso no eliminamos todas las filas con algún dato ausente.

CO_2 y NOx presentan distribuciones con predominio de valores bajos y algunos altos. Se identificaron 68 valores elevados de CO_2 y 198 de NOx mediante el criterio intercuartílico. Se revisaron junto con el modelo y el procedimiento; ser un valor atípico no fue suficiente para eliminarlo. Los faltantes se revisan en la sección 1, Valores Nulos; los extremos, en el apartado 1.1, CO2 (g/mi) y NOx (g/mi).

2.3. Limpieza y preparación de la base

Revisamos los valores sospechosos antes de modificarlos. La Tabla 1 resume las correcciones aplicadas en la copia de trabajo. El reemplazo por NaN señala un dato no disponible para esa variable y conserva la información restante del registro.

Variable	Decisión aplicada	Registros
Cilindrada	Se reemplazó por NaN en electricidad y en 10 ensayos con hidrógeno que registran el centinela 0.001 L.	664
Potencia	Se reemplazaron por NaN los valores de 1 HP.	8
CO_2	Se reemplazó por NaN un cero sospechoso en un ensayo con combustible de combustión.	1
Economía de combustible	Se reemplazaron por NaN los valores de 999 MPG o superiores, considerados no utilizables en el análisis.	24

Tabla 1. Correcciones realizadas en la base de trabajo. Fuente: TPE.ipynb, apartado 1.1, Valores atípicos, y consolidación en la sección 2.

Se conservaron los valores altos de potencia, peso y emisiones que no presentaban evidencia suficiente de error. También se mantuvieron las categorías poco frecuentes de transmisión, tracción, combustible y procedimiento. En el caso de un modelo F150 con una posible contradicción entre su nombre y la tracción declarada, se señaló la inconsistencia sin cambiar el dato porque el archivo no permite decidir cuál de los campos es incorrecto.

La base final conserva **4287 filas y 14 columnas de interés**. Los faltantes no se completaron con valores inventados: para cada hipótesis se seleccionaron los registros con la información necesaria. Por ejemplo, un ensayo sin MPG puede seguir siendo útil para estudiar cilindros o emisiones.

Para los análisis urbanos se seleccionaron los procedimientos FTP convencionales, se descartaron las repeticiones del mismo ensayo y se calculó una mediana por configuración. En las cinco configuraciones probadas con gasolina y E85 se eligió gasolina para no combinar ambos combustibles. Los vehículos diésel se conservaron. Para comparar procedimientos se mantuvo la identificación de la configuración, ya que sus mediciones están relacionadas.

Los valores 99.99, 99.999 y 0.001 L se revisaron como centinelas. Fuera de electricidad solo aparecen en 10 ensayos con hidrógeno, ya excluidos de las hipótesis de combustión. Estas decisiones evitan que una configuración con muchos ensayos tenga más peso solo por aparecer más veces. No garantizan, sin embargo, que las configuraciones de un mismo vehículo sean independientes. Esa limitación se tuvo en cuenta al interpretar los resultados.

3. Hipótesis y resolución

En todos los contrastes se utilizó un nivel de significación del 5 %. Las primeras tres hipótesis corresponden al enunciado y las restantes fueron propuestas por el grupo. Se informa el resultado para el subconjunto analizado, sin interpretarlo como una relación causal.

3.1. Hipótesis 1

3.1.1. Definición de la hipótesis

La mayoría de las configuraciones de vehículos a combustión alcanza al menos 25 MPG urbanos. Interesa conocer cuántas superan un umbral de eficiencia, no solamente cuál es el promedio de MPG.

3.1.2. Estrategia de abordaje

Usamos una mediana urbana por configuración y un test Z para una proporción. La hipótesis nula establece una proporción menor o igual al 50 %; la alternativa, una proporción mayor. Se analizaron 1077 configuraciones con MPG disponible. El tamaño permite la aproximación normal. Preparación y contraste: apartado 4A del notebook.

3.1.3. Resultados obtenidos y discusión

653 de 1077 configuraciones cumplen el umbral: **60,63 %**. El test dio $Z = 6{,}9779$ y $p \approx 1{,}50 \times 10^{-12}$. **La hipótesis recibe respaldo en el subconjunto urbano**, bajo el supuesto de independencia. Las 1077 configuraciones corresponden a 727 vehículos. Este test Z no ajusta la incertidumbre por vehículo, a diferencia de los modelos de las hipótesis 3 y 6; su p-valor queda condicionado a la independencia. La base no es una muestra aleatoria de todos los vehículos.

3.2. Hipótesis 2

3.2.1. Definición de la hipótesis

La economía de combustible difiere según el sistema de tracción. Esta comparación permite explorar si los grupos de tracción presentan distintos resultados, manteniendo las condiciones urbanas.

3.2.2. Estrategia de abordaje

Comparamos los cinco grupos mediante Kruskal–Wallis. Shapiro y Levene indicaron falta de normalidad y varianzas distintas. La hipótesis nula plantea distribuciones iguales y la alternativa, una diferencia en al menos un grupo. No interpretamos el test exclusivamente como una comparación de medianas. El post-hoc compara los diez pares con Mann–Whitney y Holm, manteniendo el supuesto de independencia. Cálculos y boxplot: apartado 4B.

3.2.3. Resultados obtenidos y discusión

Con 1077 configuraciones, obtuvimos $H = 415{,}7847$ y $p \approx 1{,}08 \times 10^{-88}$. **Hay evidencia de diferencias según la tracción.** La mediana es 33,80 MPG para tracción delantera y entre 22,25 y 26,20 MPG en los demás grupos. El post-hoc de Mann–Whitney con Holm muestra diferencias de FWD frente a todos los demás, de RWD frente a AWD y de 4WD frente a AWD; los otros pares no resultan significativos. No demuestra que la tracción sea la causa. La posible dependencia entre configuraciones limita la inferencia.

3.3. Hipótesis 3

3.3.1. Definición de la hipótesis

Peso, potencia, cilindrada, cantidad de cilindros, transmisión y tracción están asociados conjuntamente con la economía urbana. El objetivo es estudiar esas características en conjunto, en lugar de analizarlas por separado.

3.3.2. Estrategia de abordaje

Ajustamos una regresión lineal múltiple sobre 1072 configuraciones de 723 vehículos; cinco configuraciones se excluyeron por faltantes. La hipótesis nula establece que todos los coeficientes explicativos son cero; la alternativa, que al menos uno no lo es. Transmisión y tracción se representaron como categorías.

Los gráficos y las pruebas de residuos mostraron falta de normalidad y varianza desigual. Por eso usamos un contraste global robusto agrupado por vehículo, que contempla diferencias de varianza y relación entre configuraciones del mismo vehículo. Breusch–Pagan complementa los gráficos como diagnóstico de varianza desigual. El ajuste y sus comprobaciones se encuentran en el apartado 4C.

3.3.3. Resultados obtenidos y discusión

El modelo explica aproximadamente el 69,7 % de la variación observada de MPG urbano. El contraste robusto dio $F = 76{,}4382$ y $p \approx 4{,}36 \times 10^{-132}$. **Hay evidencia de asociación conjunta**, bajo los supuestos del modelo. El VIF es 10,40 para cilindros y 7,18 para cilindrada, con correlación 0,918. Sus coeficientes (+1,71 y −2,85) son asociaciones parciales; el signo de cilindros no implica una mejora de economía al agregar cilindros. Sin cilindros, el R^2 baja de 0,6966 a 0,6908. Se conserva el modelo conjunto, con cautela sobre los coeficientes individuales. Automatic y Semi-Automatic tienen VIF 14,89 y 16,99, asociados también al desequilibrio entre categorías y a una referencia de solo 16 casos.

3.4. Hipótesis 4

3.4.1. Definición de la hipótesis

Más de la mitad de las configuraciones de combustión tiene cuatro cilindros o menos. La presencia frecuente de motores de cuatro cilindros en la exploración motivó comprobar si ese predominio también aparece al contar configuraciones únicas.

3.4.2. Estrategia de abordaje

Se consideraron todos los procedimientos, porque el número de cilindros es una característica del motor. De 1099 configuraciones, tres no tenían ese dato. Aplicamos un test Z: hipótesis nula, proporción menor o igual al 50 %; alternativa, mayor al 50 %. El tamaño permite la aproximación normal. Cálculos: apartado 4D.

3.4.3. Resultados obtenidos y discusión

630 de 1096 configuraciones tienen cuatro cilindros o menos: **57,48 %**. El resultado fue $Z = 4{,}9538$ y $p \approx 3{,}64 \times 10^{-7}$. **La hipótesis recibe respaldo en la base analizada**, condicionado a la independencia entre configuraciones. Este test Z tampoco ajusta la incertidumbre por vehículo: su p-valor depende de ese supuesto y no equivale a la inferencia agrupada de los modelos. No representa una estimación directa de los vehículos vendidos o en circulación.

3.5. Hipótesis 5

3.5.1. Definición de la hipótesis

Las emisiones de CO_2 difieren según el procedimiento y son menores en autopista que en urbano, conducción agresiva (US06), aire acondicionado (SC03) y frío. Interesa distinguir cuánto cambia el resultado cuando se modifica la condición de ensayo de una misma configuración.

3.5.2. Estrategia de abordaje

De 1091 configuraciones con algún ciclo disponible, seleccionamos las 196 con mediciones en los cinco ciclos. Comparamos la mediana de cada ciclo con la de autopista mediante una prueba de signos pareada. Para cada comparación, la hipótesis nula plantea que las diferencias positivas no superan el 50 % de los pares sin empate; la alternativa, que sí lo superan.

La prueba no requiere normalidad ni simetría de las diferencias. Holm ajusta los cuatro p-valores para limitar la probabilidad de algún rechazo erróneo al realizar varias comparaciones. La preparación, los contrastes y la Figura 2 corresponden al apartado 4E del notebook.

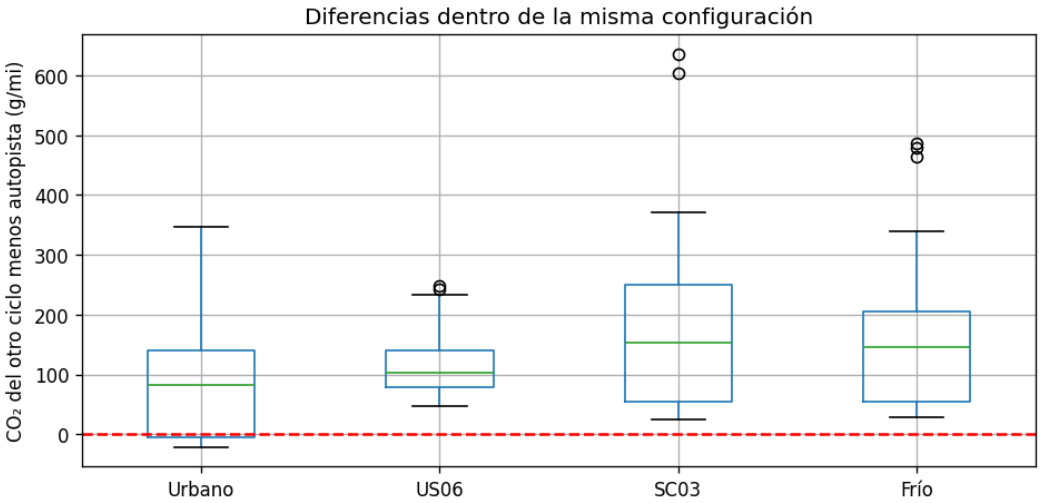


Figura 2. Diferencias de CO_2 frente a autopista para las mismas 196 configuraciones. Los valores positivos indican mayores emisiones en el otro ciclo.

3.5.3. Resultados obtenidos y discusión

Las diferencias medianas fueron 82,04 g/mi en urbano, 103,13 en US06, 153,00 en SC03 y 146,65 en frío. Los cuatro p-valores ajustados son menores que 0,05; el mayor es aproximadamente $3{,}18 \times 10^{-7}$. En urbano, 133 de 196 configuraciones emitieron más que en autopista; en los otros ciclos fueron las 196.

La dirección de la hipótesis recibe respaldo. No afirmamos que autopista sea menor en todos los casos. Tampoco se definió de antemano un umbral para considerar una diferencia “sustancial”, por lo que informamos su magnitud sin dar por validado ese término. Los 196 casos completos no representan toda la base: 63 tienen CO_2 urbano menor o igual que en autopista, sin que el nombre del modelo permita confirmar si son híbridos. Repetir las pruebas con todos los pares disponibles mantiene la conclusión; la selección y la posible dependencia entre configuraciones limitan el alcance.

3.6. Hipótesis 6

3.6.1. Definición de la hipótesis

El CO_2 está asociado conjuntamente con peso, cilindrada, potencia y procedimiento, y el aumento de emisiones asociado al peso y la cilindrada se intensifica en urbano, US06 y frío respecto de autopista. Esta hipótesis busca conocer tanto la asociación general como sus cambios entre condiciones de ensayo.

3.6.2. Estrategia de abordaje

Ajustamos una regresión múltiple con interacciones: permitimos que la pendiente del peso y de la cilindrada cambie según el ciclo, porque esa variación es parte de la hipótesis. Utilizamos 2884 observaciones de 1089 configuraciones y 731 vehículos; seis observaciones se excluyeron por faltantes. No exigimos que cada configuración tuviera los cinco ciclos.

El contraste global compara coeficientes explicativos todos iguales a cero frente a alguno distinto. Para la intensificación se contrasta, en cada una de las seis interacciones previstas, un cambio de pendiente no positivo frente a uno positivo, con corrección de Holm. Los residuos mostraron falta de normalidad y varianza desigual; usamos inferencia robusta agrupada por vehículo. Cálculos y gráficos de residuos: apartado 4F.

3.6.3. Resultados obtenidos y discusión

El modelo explica aproximadamente el 80,8 % de la variación observada de CO_2. El contraste global robusto dio $F \approx 701{,}42$ y $p < 0{,}001$, lo que respalda la asociación conjunta. Sin embargo, el comportamiento previsto no aparece en todas las interacciones.

Característica	Urbano	US06	Frío
Peso	No se respalda	Se respalda	Se respalda
Cilindrada	Se respalda	Se respalda	Se respalda

Tabla 2. Evidencia de aumento de la pendiente respecto de autopista, con corrección de Holm. Fuente: TPE.ipynb, apartado 4F.

En urbano, el cambio de pendiente del peso es negativo: aproximadamente −4,98 g/mi por cada 1000 lb respecto de autopista. Por eso, **la hipótesis completa recibe respaldo parcial**: hay asociación conjunta e intensificación en varias condiciones, pero no en todas las planteadas.

Los resultados describen asociaciones dentro del modelo, no efectos causales. El ajuste robusto contempla parte de la dependencia y la varianza desigual, pero no corrige variables omitidas, una relación mal representada o la selección de los ensayos.

4. Conclusiones

El análisis mostró que la preparación de los datos era necesaria para interpretar los resultados. Las 4287 filas no representan 4287 vehículos distintos: una misma configuración puede tener varios ensayos. Por eso, contar configuraciones y distinguir los procedimientos fue una parte central del trabajo.

En el subconjunto evaluado, el 60,63 % de las configuraciones alcanzó al menos 25 MPG urbanos y el 57,48 % tuvo cuatro cilindros o menos. También encontramos diferencias de economía urbana entre grupos de tracción y asociación conjunta con las características técnicas del vehículo.

Las comparaciones de emisiones respaldaron la dirección esperada: autopista presentó menores emisiones con mayor frecuencia que los otros ciclos. La hipótesis multivariada propia quedó parcialmente respaldada, porque el efecto asociado al peso no se intensificó en urbano como se había planteado.

Las conclusiones corresponden a los ensayos seleccionados. La base no es una muestra aleatoria de todos los vehículos y algunas configuraciones pueden estar relacionadas. Además, los modelos mostraron limitaciones en sus residuos. Por eso los resultados aportan evidencia sobre estas asociaciones, pero no permiten afirmar causalidad ni trasladar automáticamente los valores a la conducción real.

Referencias

[1] Environmental Protection Agency. Data on Cars used for Testing Fuel Economy. Datos de vehículos año modelo 2025. Consulta: 9 de noviembre de 2026.
https://www.epa.gov/compliance-and-fuel-economy-data/data-cars-used-testing-fuel-economy

[2] U.S. Department of Energy y Environmental Protection Agency. Detailed Test Information. Consulta: 9 de noviembre de 2026.
https://www.fueleconomy.gov/feg/fe_test_schedules.shtml

[3] Fundamentos de la Ciencia de Datos, cursada 2026. Economía de combustible y características técnicas en vehículos. Guía de contexto y diccionario de variables. Material provisto con el trabajo práctico.

Los resultados, tablas y figuras del análisis se encuentran en TPE.ipynb, secciones 1 a 4F. El archivo de datos utilizado es 25-testcar-2026-01-21.xlsx.