2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

EPA Fuel Economy 2025

Grupo 13

Sanchez Islas Joaquin

Bejarano Rodrigo Ruben

Hultstrom Denda Joaquín

1. Introducción

La economía de combustible y las emisiones de un vehículo dependen tanto de sus características como de las condiciones en las que circula. Un mismo vehículo puede dar resultados distintos en ciudad, en autopista o en una prueba a baja temperatura. Por eso, para comparar vehículos es necesario tener en cuenta cómo se realizaron los ensayos.

En este trabajo analizamos EPA Fuel Economy, correspondiente a vehículos de año modelo 2025. La base reúne ensayos realizados por la Agencia de Protección Ambiental de Estados Unidos (EPA) y por fabricantes que informan sus resultados al organismo. Estos datos se utilizan en la elaboración de estimaciones de economía de combustible y en programas vinculados con la eficiencia vehicular [1].

El archivo contiene **4287 registros y 67 variables**. Incluye información del fabricante, motor, transmisión, tracción, combustible, procedimiento y emisiones. La economía de combustible se expresa en millas por galón (MPG): un valor mayor indica que se recorre más distancia con la misma cantidad de combustible.

El objetivo fue conocer la base, revisar sus problemas y evaluar seis hipótesis: tres propuestas por la cátedra y tres planteadas por el grupo. Trabajamos principalmente con vehículos ensayados con combustibles de combustión. Los procedimientos urbanos, de autopista, conducción agresiva, aire acondicionado y frío representan condiciones diferentes y no se mezclaron sin distinguirlas [2].

Durante la exploración encontramos valores faltantes, algunas mediciones sospechosas y varias filas para una misma configuración. Conservamos la base original, realizamos las correcciones en una copia y seleccionamos los datos necesarios para cada análisis. La limpieza y la preparación de cada hipótesis se detallan en las secciones siguientes.

El informe presenta primero el análisis exploratorio y la limpieza. Luego desarrolla las seis hipótesis, su forma de evaluación y sus resultados. Por último, reúne las conclusiones y las limitaciones. Los cálculos se encuentran en **TPE.ipynb**: secciones 1 y 2 para exploración y limpieza, sección 3 para las hipótesis propias y apartados 4A a 4F para su validación.

2. Análisis exploratorio de los datos

2.1. Estructura y principales observaciones

Cada fila representa un registro de ensayo, no necesariamente un vehículo diferente. Identificamos **1448 configuraciones**, de las cuales 1293 aparecen en más de un registro. La clave combina código del fabricante, identificador del vehículo y número de configuración, según los metadatos [3]. No encontramos filas completamente idénticas. Aunque la metadata describe Test Number como único, hay 213 identificadores repetidos (273 filas adicionales). En el subconjunto urbano de 4A son 89 identificadores y 110 filas adicionales, con MPG coincidentes; se evita contarlos dos veces. Esto motivó la preparación de una observación por configuración cuando correspondía.

La base reúne 32 códigos de fabricante, 14 procedimientos, 11 tipos de combustible y cinco sistemas de tracción. La gasolina Tier 2 concentra 3236 registros (75,48 %) y la electricidad, 654 (15,26 %). Estas frecuencias describen los ensayos disponibles, no las ventas ni la composición del parque automotor.

La potencia tiene una mediana de 305 HP y una media de 340,70 HP. La Figura 1 muestra que hay pocos registros muy elevados y una mayor concentración en valores menores. El peso equivalente de ensayo tiene una mediana de 4750 lb. Los motores de cuatro, seis y ocho cilindros predominan entre los registros con ese dato. Estas observaciones motivaron estudiar la cantidad de cilindros y la relación de las características técnicas con la economía de combustible.

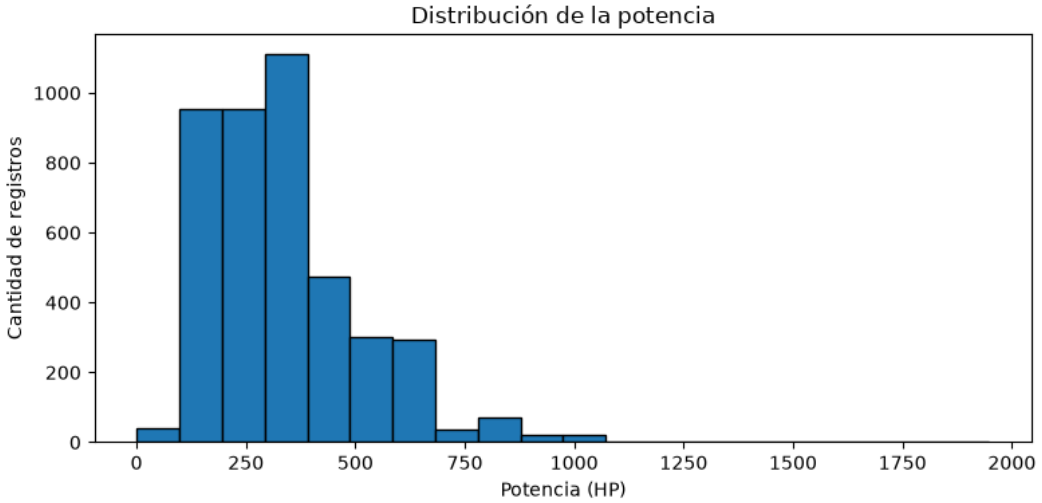


Figura 1. Distribución de potencia en los registros originales. Fuente: TPE.ipynb, sección 1, apartado Rated Horsepower.

2.2. Valores faltantes y emisiones

Hay faltantes en 24 de las 67 variables. Su presencia no siempre indica un error: los campos ADFE solo se completan cuando la economía de combustible se deriva analíticamente. Por eso no eliminamos todas las filas con algún dato ausente.

CO_2 y NOx presentan distribuciones con predominio de valores bajos y algunos altos. Se identificaron 68 valores elevados de CO_2 y 198 de NOx mediante el criterio intercuartílico. Se revisaron junto con el modelo y el procedimiento; ser un valor atípico no fue suficiente para eliminarlo. Los faltantes se revisan en la sección 1, Valores Nulos; los extremos, en el apartado 1.1, CO2 (g/mi) y NOx (g/mi).

2.3. Limpieza y preparación de la base

Revisamos los valores sospechosos antes de modificarlos. La Tabla 1 resume las correcciones aplicadas en la copia de trabajo. El reemplazo por NaN señala un dato no disponible para esa variable y conserva la información restante del registro.

Variable	Decisión aplicada	Registros
Cilindrada	Se reemplazó por NaN en electricidad y en 10 ensayos con hidrógeno que registran el centinela 0.001 L.	664
Potencia	Se reemplazaron por NaN los valores de 1 HP.	8
CO_2	Se reemplazó por NaN un cero sospechoso en un ensayo con combustible de combustión.	1
Economía de combustible	Se reemplazaron por NaN los valores de 999 MPG o superiores, considerados no utilizables en el análisis.	24

Tabla 1. Correcciones realizadas en la base de trabajo. Fuente: TPE.ipynb, apartado 1.1, Valores atípicos, y consolidación en la sección 2.

Se conservaron los valores altos de potencia, peso y emisiones que no presentaban evidencia suficiente de error. También se mantuvieron las categorías poco frecuentes de transmisión, tracción, combustible y procedimiento. En el caso de un modelo F150 con una posible contradicción entre su nombre y la tracción declarada, se señaló la inconsistencia sin cambiar el dato porque el archivo no permite decidir cuál de los campos es incorrecto.

La base final conserva **4287 filas y 14 columnas de interés**. Los faltantes no se completaron con valores inventados: para cada hipótesis se seleccionaron los registros con la información necesaria. Por ejemplo, un ensayo sin MPG puede seguir siendo útil para estudiar cilindros o emisiones.

Para los análisis urbanos se seleccionaron los procedimientos FTP convencionales, se descartaron las repeticiones del mismo ensayo y se calculó una mediana por configuración. En las cinco configuraciones probadas con gasolina y E85 se eligió gasolina para no combinar ambos combustibles. Los vehículos diésel se conservaron. Para comparar procedimientos se mantuvo la identificación de la configuración, ya que sus mediciones están relacionadas.

Los valores 99.99, 99.999 y 0.001 L se revisaron como centinelas. Fuera de electricidad solo aparecen en 10 ensayos con hidrógeno, ya excluidos de las hipótesis de combustión. Estas decisiones evitan que una configuración con muchos ensayos tenga más peso solo por aparecer más veces. No garantizan, sin embargo, que las configuraciones de un mismo vehículo sean independientes. Esa limitación se tuvo en cuenta al interpretar los resultados.

3. Hipótesis y resolución

En todos los contrastes se utilizó un nivel de significación del 5 %. Las primeras tres hipótesis corresponden al enunciado y las restantes fueron propuestas por el grupo. Se informa el resultado para el subconjunto analizado, sin interpretarlo como una relación causal.

Variables de la validación	Tipo y unidad
Economía y emisiones de CO_2	Cuantitativas: MPG y g/mi
Peso, cilindrada y potencia	Cuantitativas: lb, L y HP
Cilindros; transmisión, tracción y ciclo	Conteo; categorías nominales

3.1. Hipótesis 1

3.1.1. Definición de la hipótesis

La mayoría de las configuraciones de vehículos a combustión alcanza al menos 25 MPG urbanos. Interesa conocer cuántas superan un umbral de eficiencia, no solamente cuál es el promedio de MPG.

3.1.2. Estrategia de abordaje

Tomamos la mediana urbana de cada configuración y contamos cuántas llegan a 25 MPG. Con chi-cuadrado de bondad de ajuste comparamos los conteos con lo esperado si la proporción fuera 50 % (538,5 por categoría). La alternativa es una diferencia en cualquier dirección; para hablar de mayoría, la proporción observada debe ser superior. Notebook: 4A [4, 6].

3.1.3. Resultados obtenidos y discusión

653 de 1077 configuraciones alcanzan el umbral (60,63 %). El reparto difiere de 50/50 ($\chi^2 = 48{,}69$; 1 gl; $p \approx 3{,}0 \times 10^{-12}$), en la dirección planteada. Las configuraciones corresponden a 727 vehículos; su posible dependencia limita la inferencia.

3.2. Hipótesis 2

3.2.1. Definición de la hipótesis

En vehículos de combustión, la economía de combustible difiere según el sistema de tracción. Se comparan configuraciones en condiciones urbanas equivalentes.

3.2.2. Estrategia de abordaje

Kruskal–Wallis contrasta igualdad de distribuciones entre los cinco grupos. Shapiro y Levene desaconsejan comparar medias mediante ANOVA. Para explorar los diez pares aplicamos Levene: si detecta varianzas distintas usamos Kruskal–Wallis de dos grupos; en los demás pares usamos Mann–Whitney. Notebook: 4B [5].

3.2.3. Resultados obtenidos y discusión

Hay diferencias globales en los rangos de MPG ($H = 415{,}78$; $p < 0{,}001$). Los p-valores por par, sin ajustar, sugieren diferencias de delantera frente a los otros grupos, trasera frente a integral y 4WD frente a integral. Son indicios exploratorios: se hicieron diez comparaciones y el grupo de tracción parcial tiene solo 11 casos (frente a delantera, $p = 0{,}0062$). La tracción no queda identificada como causa.

3.3. Hipótesis 3

3.3.1. Definición de la hipótesis

Peso, potencia, cilindrada, cantidad de cilindros, transmisión y tracción están asociados conjuntamente con la economía urbana. El objetivo es estudiar esas características en conjunto, en lugar de analizarlas por separado.

3.3.2. Estrategia de abordaje

Ajustamos una regresión lineal múltiple sobre 1072 configuraciones de 723 vehículos; cinco configuraciones se excluyeron por faltantes. La hipótesis nula establece que todos los coeficientes explicativos son cero; la alternativa, que al menos uno no lo es. Transmisión y tracción se representaron como categorías.

Revisamos residuos frente a ajustados, el gráfico Q–Q, Shapiro y el VIF. Los residuos no se ajustan bien a la normalidad, su dispersión cambia y hay configuraciones de un mismo vehículo. Por eso interpretamos la F convencional con cautela. Notebook: 4C [4, 5, 7].

3.3.3. Resultados obtenidos y discusión

El ajuste explica el 69,7 % de la variación observada ($F = 173{,}36$; p nominal < 0,001). Describe asociación conjunta en la base, sin confirmar una relación poblacional bajo estos supuestos. Cilindros y cilindrada tienen correlación 0,918 y VIF 10,40 y 7,18: sus coeficientes (+1,71 y −2,85) son difíciles de separar. Sin cilindros, el R^2 pasa de 0,6966 a 0,6908. Las indicadoras de transmisión también reflejan una categoría de referencia poco frecuente.

3.4. Hipótesis 4

3.4.1. Definición de la hipótesis

Más de la mitad de las configuraciones de combustión tiene cuatro cilindros o menos. Las metas de eficiencia favorecen motores más pequeños; el turbo o la asistencia eléctrica pueden compensar parte de la potencia. Esto motiva preguntar si las configuraciones con hasta cuatro cilindros predominan entre las ensayadas.

3.4.2. Estrategia de abordaje

De 1099 configuraciones, tres no informan cilindros. Para las 1096 evaluables comparamos las frecuencias observadas con un reparto 50/50 (548 por grupo) mediante chi-cuadrado de bondad de ajuste. El contraste detecta diferencias en ambos sentidos. Notebook: 4D [4, 6].

3.4.3. Resultados obtenidos y discusión

630 de 1096 configuraciones tienen cuatro cilindros o menos (57,48 %). El reparto difiere de 50/50 ($\chi^2 = 24{,}54$; 1 gl; $p \approx 7{,}28 \times 10^{-7}$) y el sentido observado respalda la hipótesis. Configuraciones del mismo vehículo pueden estar relacionadas, por lo que el p-valor supone más independencia de la que podemos verificar.

3.5. Hipótesis 5

3.5.1. Definición de la hipótesis

En vehículos de combustión esperamos menores emisiones de CO_2 en autopista que en urbano, US06, SC03 y frío. En autopista se sostiene una velocidad más estable; en ciudad y en US06 se vuelve a acelerar con frecuencia. El aire acondicionado de SC03 y el arranque en frío también pueden aumentar el consumo por milla.

3.5.2. Estrategia de abordaje

De 1091 configuraciones con algún ciclo, 196 tienen los cinco. Aplicamos Friedman por bloques: cada configuración aporta una medición por ciclo. La nulidad plantea que no hay diferencias sistemáticas entre sus rangos; la alternativa, que al menos un ciclo difiere.

Friedman no exige normalidad, pero supone independencia entre configuraciones. Para saber en qué dirección van las diferencias, restamos a cada ciclo el CO_2 de autopista de la misma configuración. Las medianas describen la magnitud; no son pruebas separadas de significación. Notebook: 4E [4, 6].

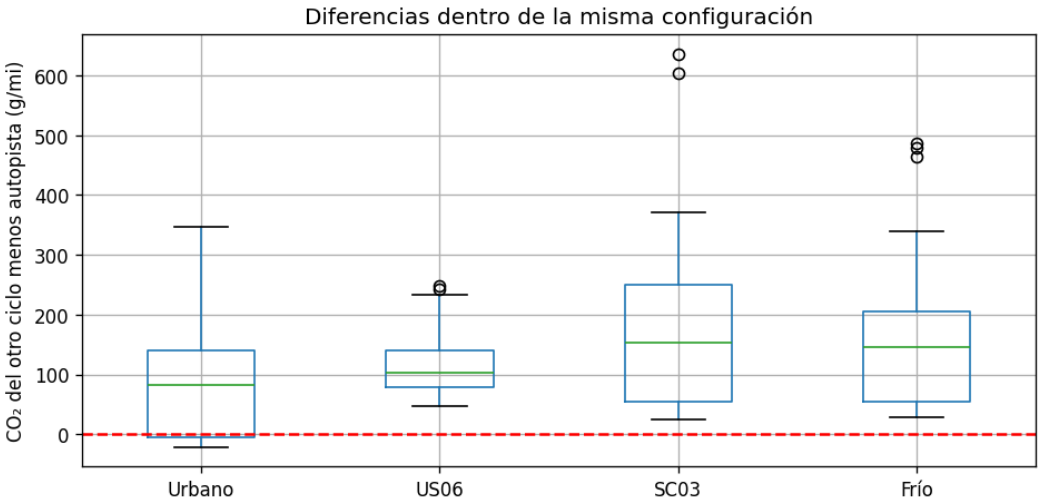


Figura 2. Diferencias de CO_2 frente a autopista para las mismas 196 configuraciones. Los valores positivos indican mayores emisiones en el otro ciclo.

3.5.3. Resultados obtenidos y discusión

Los rangos difieren entre los cinco ciclos (Friedman: $\chi^2 = 523{,}72$; 4 gl). El p-valor de SciPy es aproximado: con cinco ciclos no conviene atribuir precisión a su valor extremo [6]. Las diferencias medianas frente a autopista son +82,04 g/mi en urbano, +103,13 en US06, +153,00 en SC03 y +146,65 en frío. En urbano, 63 de las 196 configuraciones no superan a autopista.

El contraste global respalda que el procedimiento importa y las medianas van en la dirección esperada, incluso al aprovechar todos los pares disponibles. No se fijó un umbral de importancia práctica y los casos completos no representan necesariamente al resto.

3.6. Hipótesis 6

3.6.1. Definición de la hipótesis

La hipótesis relaciona CO_2 con peso, cilindrada, potencia y procedimiento, y anticipa mayor penalización por peso y cilindrada en urbano, US06 y frío que en autopista. Acelerar un vehículo más pesado requiere más energía, especialmente con cambios de velocidad frecuentes. Una mayor cilindrada también puede asociarse con más consumo bajo carga; de ahí la comparación entre ciclos.

3.6.2. Estrategia de abordaje

Ajustamos una regresión múltiple con peso, cilindrada, potencia y ciclo, tomando autopista como referencia. Usamos 2884 observaciones de 1089 configuraciones de 731 vehículos. La F compara este ajuste con un modelo de solo intercepto; el gráfico de residuos, el Q–Q y Shapiro permiten revisar los supuestos.

Para explorar la segunda parte de la hipótesis ajustamos por separado CO_2 en función de peso, cilindrada y potencia en los cuatro ciclos de interés, siempre sobre las mismas 196 configuraciones. Así comparamos pendientes sin que cambie el conjunto de vehículos. Notebook: 4F [5, 7].

3.6.3. Resultados obtenidos y discusión

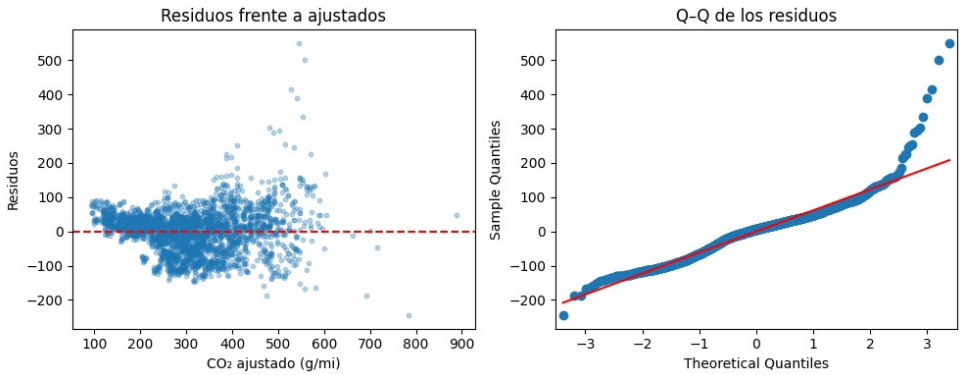


Figura 3. Residuos del modelo de CO_2 frente a los valores ajustados (izquierda) y gráfico Q–Q (derecha). El alejamiento de la recta en los extremos limita la interpretación de la F. Fuente: TPE.ipynb, apartado 4F.

El modelo conjunto explica el 74,8 % de la variación observada (F = 1219,05; p nominal < 0,001). Los residuos se apartan de la normalidad y varias mediciones corresponden al mismo vehículo. El ajuste describe asociación; la F convencional no basta para confirmarla en la población.

Ciclo	Peso: g/mi por 1000 lb	Cilindrada: g/mi por litro
Autopista	30,63	8,51
Urbano	24,56	24,49
US06	65,23	15,25
Frío	42,80	18,20

Pendientes ajustadas por ciclo en las mismas configuraciones. Fuente: TPE.ipynb, apartado 4F.

En los tres ciclos la pendiente de cilindrada supera a la de autopista. Para el peso solo ocurre en US06 y frío. Son diferencias descriptivas: no prueban significación entre pendientes ni causalidad.

4. Conclusiones

El análisis mostró que la preparación de los datos era necesaria para interpretar los resultados. Las 4287 filas no representan 4287 vehículos distintos: una misma configuración puede tener varios ensayos. Por eso, contar configuraciones y distinguir los procedimientos fue una parte central del trabajo.

En el subconjunto evaluado, el 60,63 % de las configuraciones alcanzó al menos 25 MPG urbanos y el 57,48 % tuvo cuatro cilindros o menos. También encontramos diferencias de economía urbana entre grupos de tracción y asociación conjunta con las características técnicas del vehículo.

Los rangos de CO_2 difieren entre procedimientos y las diferencias medianas favorecen a autopista. En los ajustes por ciclo, el aumento esperado de la pendiente del peso no aparece en urbano. Por eso la hipótesis de intensificación no queda confirmada en su totalidad.

Las conclusiones corresponden a los ensayos seleccionados. La base no es una muestra aleatoria de todos los vehículos y algunas configuraciones pueden estar relacionadas. Además, los modelos mostraron limitaciones en sus residuos. Por eso los resultados aportan evidencia sobre estas asociaciones, pero no permiten afirmar causalidad ni trasladar automáticamente los valores a la conducción real.

Referencias

[1] Environmental Protection Agency. Data on Cars used for Testing Fuel Economy. Datos de vehículos año modelo 2025. Consulta: 9 de noviembre de 2026.
https://www.epa.gov/compliance-and-fuel-economy-data/data-cars-used-testing-fuel-economy

[2] U.S. Department of Energy y Environmental Protection Agency. Detailed Test Information. Consulta: 9 de noviembre de 2026.
https://www.fueleconomy.gov/feg/fe_test_schedules.shtml

[3] Fundamentos de la Ciencia de Datos, cursada 2026. Economía de combustible y características técnicas en vehículos. Guía de contexto y diccionario de variables. Material provisto con el trabajo práctico.

[4] Fundamentos de la Ciencia de Datos, 2026. Clase 3, diap. 24: chi-cuadrado de bondad de ajuste; Clase 5, diap. 25: Friedman para más de dos muestras relacionadas; Clase 9, diap. 28: diagnóstico de multicolinealidad mediante VIF.

[5] Material práctico de la asignatura, 2026. Práctica 4: codificación de categorías; Práctica 6: Shapiro–Wilk, Levene y comparación de grupos; Práctica 9: regresión múltiple, F y gráficos de residuos.

[6] SciPy. Documentación de las funciones utilizadas (versión de ejecución: 1.16.3): chisquare, friedmanchisquare, shapiro, levene, kruskal, mannwhitneyu.

[7] statsmodels. Documentación de las funciones utilizadas (versión de ejecución: 0.15.0): OLS, ols por fórmula, Q–Q, VIF.

Los resultados, tablas y figuras del análisis se encuentran en TPE.ipynb, secciones 1 a 4F. El archivo de datos utilizado es 25-testcar-2026-01-21.xlsx.